homework1

第一次作业：混凝土抗压强度预测

1. 任务介绍

1.1 问题类型

本次作业是一个典型的**回归问题（Regression）**。回归问题的目标是让模型输出一个连续的标量值，与分类问题（输出离散类别）不同。

以课件中的例子类比：

- 预测上海股市明日指数 → 回归
- 预测自动驾驶汽车行驶方向 → 回归
- 本作业：给定混凝土配方 → 预测抗压强度（MPa）→ **回归**

1.2 数据集介绍

本数据集为混凝土抗压强度数据，共**1030个样本，8个输入特征，1个输出变量**。

特征	说明	单位
cement	水泥用量	kg/m³
slag	矿渣用量	kg/m³
flyash	粉煤灰用量	kg/m³
water	水用量	kg/m³
superplasticizer	超塑化剂用量	kg/m³
coarseaggregate	粗骨料用量	kg/m³
fineaggregate	细骨料用量	kg/m³
age	养护天数	天
csMPa	**混凝土抗压强度（输出变量）**	**MPa**

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import torch
import torch.nn as nn
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from torch.utils.data import TensorDataset, DataLoader

plt.rcParams['font.sans-serif'] = ['Microsoft YaHei']

df = pd.read_csv('Concrete_Data_Yeh.csv')
print('数据大小：', df.shape)
print('\n前5行数据预览：')
```

```python
print(df.head())
print('\n基本统计信息：')
print(df.describe())
```

```
数据大小： (1030, 9)

前5行数据预览：
   cement   slag  flyash  water  superplasticizer  coarseaggregate  \
0   540.0    0.0     0.0  162.0               2.5           1040.0
1   540.0    0.0     0.0  162.0               2.5           1055.0
2   332.5  142.5     0.0  228.0               0.0            932.0
3   332.5  142.5     0.0  228.0               0.0            932.0
4   198.6  132.4     0.0  192.0               0.0            978.4

   fineaggregate  age  csMPa
0          676.0   28  79.99
1          676.0   28  61.89
2          594.0  270  40.27
3          594.0  365  41.05
4          825.5  360  44.30

基本统计信息：
            cement         slag       flyash        water  superplasticizer  \
count  1030.000000  1030.000000  1030.000000  1030.000000       1030.000000
mean    281.167864    73.895825    54.188350   181.567282          6.204660
std     104.506364    86.279342    63.997004    21.354219          5.973841
min     102.000000     0.000000     0.000000   121.800000          0.000000
25%     192.375000     0.000000     0.000000   164.900000          0.000000
50%     272.900000    22.000000     0.000000   185.000000          6.400000
75%     350.000000   142.950000   118.300000   192.000000         10.200000
max     540.000000   359.400000   200.100000   247.000000         32.200000

       coarseaggregate  fineaggregate          age        csMPa
count      1030.000000    1030.000000  1030.000000  1030.000000
mean        972.918932     773.580485    45.662136    35.817961
std          77.753954      80.175980    63.169912    16.705742
min         801.000000     594.000000     1.000000     2.330000
25%         932.000000     730.950000     7.000000    23.710000
50%         968.000000     779.500000    28.000000    34.445000
75%        1029.400000     824.000000    56.000000    46.135000
max        1145.000000     992.600000   365.000000    82.600000
```

2. 特征选择：相关性分析

2.1 为什么要进行特征选择?

数据集中共有8个输入特征，并非所有特征都与输出变量（混凝土强度）有强关联。使用相关性较低的特征可能引入噪声，影响模型效果。因此，在建模前先分析各特征与输出的相关性，有助于选择更有价值的特征。

2.2 皮尔逊相关系数

皮尔逊相关系数衡量两个变量之间的**线性相关程度**，取值范围为 $[-1, 1]$：

- 接近 $+1$：强正相关（特征增大，强度也增大）
- 接近 -1：强负相关（特征增大，强度减小）
- 接近 0：线性相关性弱

2.3 实验结论

通过对比实验发现：

- 使用相关性最高的**6个特征**建模：测试集 MSE ≈ 115
- 使用**全部8个特征**建模：测试集 MSE ≈ 110

使用全部特征效果反而更好。原因是皮尔逊相关系数只能衡量**线性关系**，slag、flyash等特征虽然与强度线性相关性低，但可能与强度存在非线性关系，删除后反而损失了有用信息。因此最终**保留全部8个特征**。

```
correlations = df.corr()['csMPa'].drop('csMPa')
correlations_abs = correlations.abs().sort_values(ascending=False)
print('各特征与混凝土强度的相关系数（绝对值）：')
print(correlations_abs)

plt.figure(figsize=(10, 5))
correlations_abs.plot(kind='bar', color='steelblue')
plt.title('各特征与混凝土强度的相关性')
plt.ylabel('相关系数（绝对值）')
plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()
```

```
各特征与混凝土强度的相关系数（绝对值）：
cement              0.497832
superplasticizer    0.366079
age                 0.328873
water               0.289633
fineaggregate       0.167241
coarseaggregate     0.164935
slag                0.134829
flyash              0.105755
Name: csMPa, dtype: float64
```

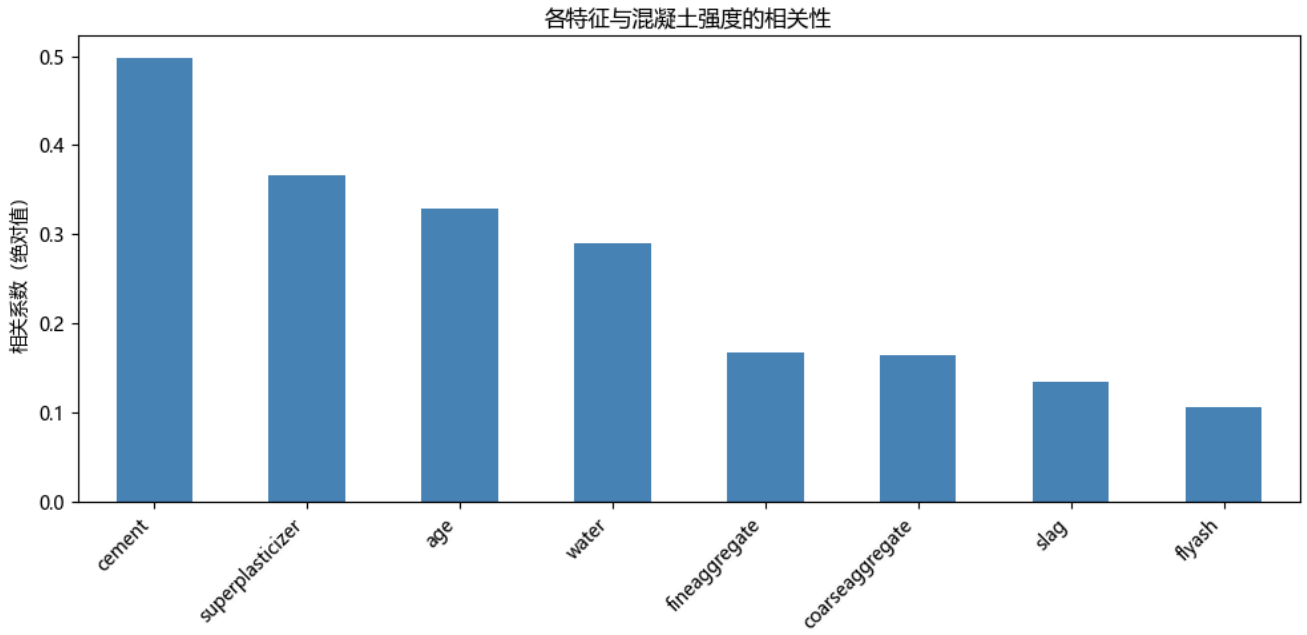

3. 数据准备与预处理

3.1 训练集与测试集划分

将数据集按 **80% 训练集、20% 测试集** 划分。训练集用于学习模型参数，测试集用于评估模型在未见过数据上的泛化能力——这与备考时用练习题学习、用模拟卷检验水平的逻辑相同。

本实验使用 `train_test_split` 对数据进行**随机打乱**后再划分。实验发现直接取前80%后20%时，由于数据集本身存在前后分布不均匀的问题，测试集MSE偏高（约150+），随机划分后测试集MSE降至合理水平。

3.2 标准化（Feature Scaling）

观察数据可以发现各特征的数值范围差异很大：

- cement：100~540 kg/m³
- superplasticizer：0~32 kg/m³
- age：1~365 天

若直接使用原始数值训练，梯度下降在不同特征方向上的步长差异极大，导致训练不稳定、收敛缓慢。

对此，对每个特征进行**Z-score标准化**：

$$x_i^r \leftarrow \frac{x_i^r - m_i}{\sigma_i}$$

其中 m_i 为第 i 个特征的均值，σ_i 为标准差。标准化后每个特征的均值为0、标准差为1，梯度下降的收敛速度和稳定性显著提升。

注意：m_i 和 σ_i 只在训练集上计算，测试集使用相同参数转换，以避免测试集信息泄露到训练过程中。

```
X = df.iloc[:, :-1].values
Y = df.iloc[:, -1].values

X_train, X_test, Y_train, Y_test = train_test_split(
    X, Y, test_size=0.2, random_state=42
)
```

```python
print('训练集大小：', X_train.shape)
print('测试集大小：', X_test.shape)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled  = scaler.transform(X_test)
print('\n标准化后训练集均值（应接近0）：', X_train_scaled.mean(axis=0).round(2))
print('标准化后训练集标准差（应接近1）：', X_train_scaled.std(axis=0).round(2))
```

```
训练集大小： (824, 8)
测试集大小： (206, 8)

标准化后训练集均值（应接近0）： [ 0. -0.  0. -0.  0.  0.  0.  0.]
标准化后训练集标准差（应接近1）： [1. 1. 1. 1. 1. 1. 1. 1.]
```

4. 方法一：线性回归 + 动量 + Adagrad

4.1 Step 1：建立模型

采用**线性模型**，假设混凝土强度与各特征之间存在线性关系：

$$y = b + \sum_{i=1}^{8} w_i x_i$$

其中 w_i 为各特征的权重（weight），b 为偏置（bias），这两组参数是我们需要通过训练学习的。

4.2 Step 2：定义损失函数

使用均方误差（MSE）作为损失函数，衡量预测值与真实值之间的差距：

$$L(w, b) = \frac{1}{N} \sum_{n=1}^{N} (\hat{y}^n - y^n)^2$$

损失函数越小，说明模型预测越准确。训练的目标就是找到使 L 最小的 w^* 和 b^*。

4.3 Step 3：梯度下降优化

普通梯度下降：

$$w \leftarrow w - \eta \frac{\partial L}{\partial w}$$

每一步沿着梯度的反方向更新参数，η 为学习率，控制步长大小。

4.4 改进一：Adagrad（自适应学习率）

普通梯度下降对所有参数使用相同的学习率，不够灵活。**Adagrad**为每个参数维护历史梯度的平方累积 G_t，自动调整每个参数的学习率：

$$\sigma^t = \sqrt{\frac{1}{t+1} \sum_{i=0}^{t} (g^i)^2 + \epsilon}$$

$$w^{t+1} \leftarrow w^t - \frac{\eta^t}{\sigma^t} g^t$$

梯度历史较大的参数，学习率自动缩小（走得稳）；梯度历史较小的参数，学习率相对较大（走得快）。

4.5 改进二：动量（Momentum）

普通梯度下降容易卡在局部最小值或鞍点。**动量**的思路是：更新方向不只看当前梯度，还参考上一步的移动方向，类似物理中的惯性：

$$m^t = \lambda m^{t-1} - \eta_t \cdot g^t$$

$$w = w + m^t$$

其中 λ 为动量系数（本实验取0.9），m^t 是当前步的移动量，它是所有历史梯度的加权求和，使参数更新更加平滑，有助于跳出局部最小值。

```
np.random.seed(42)
w = np.random.randn(8) * 0.01  # 随机初始化权重
b = 0.0                         # 偏置初始为0

lr       = 0.1    # 基础学习率
epochs   = 5000   # 训练轮数
N        = len(X_train_scaled)
momentum = 0.9    # 动量系数λ
eps      = 1e-8   # 防止除以0

m_w = np.zeros(8)  # 动量初始化
m_b = 0.0
G_w = np.zeros(8)  # Adagrad梯度平方累积
G_b = 0.0
loss_lr = []

for i in range(epochs):
    Y_pred = X_train_scaled @ w + b          # 前向传播
    loss   = np.mean((Y_train - Y_pred) ** 2)  # 计算MSE损失
    loss_lr.append(loss)

    error  = Y_train - Y_pred
    grad_w = -2/N * (X_train_scaled.T @ error)  # w的梯度
    grad_b = -2/N * np.sum(error)               # b的梯度

    G_w += grad_w ** 2                          # 累积梯度平方
    G_b += grad_b ** 2

    adaptive_lr_w = lr / (np.sqrt(G_w) + eps)   # 自适应学习率
    adaptive_lr_b = lr / (np.sqrt(G_b) + eps)

    m_w = momentum * m_w - adaptive_lr_w * grad_w  # 动量更新
    m_b = momentum * m_b - adaptive_lr_b * grad_b

    w = w + m_w                                 # 更新参数
    b = b + m_b

Y_pred_test_lr = X_test_scaled @ w + b
mse_lr  = np.mean((Y_test - Y_pred_test_lr) ** 2)
rmse_lr = np.sqrt(mse_lr)
print(f'线性回归 测试集MSE: {mse_lr:.4f}')
print(f'线性回归 测试集RMSE: {rmse_lr:.4f} MPa')
```

```
plt.figure(figsize=(8, 4))
plt.plot(loss_lr)
plt.xlabel('Epoch')
plt.ylabel('MSE Loss')
plt.title('线性回归（动量+Adagrad）训练Loss曲线')
plt.show()

plt.figure(figsize=(5, 5))
plt.scatter(Y_test, Y_pred_test_lr, alpha=0.6, s=20, color='steelblue')
plt.plot([Y_test.min(), Y_test.max()],
         [Y_test.min(), Y_test.max()], 'r--', label='理想预测线')
plt.xlabel('真实值 (MPa)')
plt.ylabel('预测值 (MPa)')
plt.title(f'线性回归: 预测值 vs 真实值\nMSE={mse_lr:.2f}')
plt.legend()
plt.show()
```

```
线性回归 测试集MSE: 95.9709
线性回归 测试集RMSE: 9.7965 MPa
```

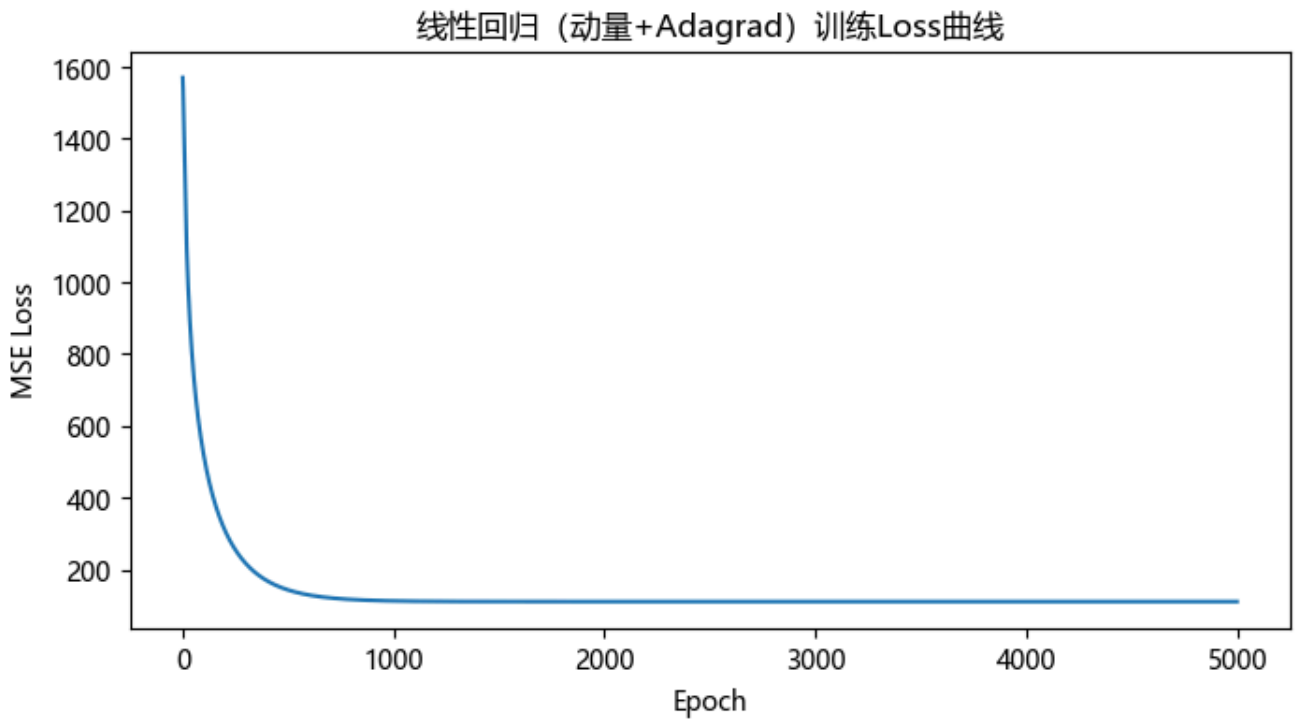

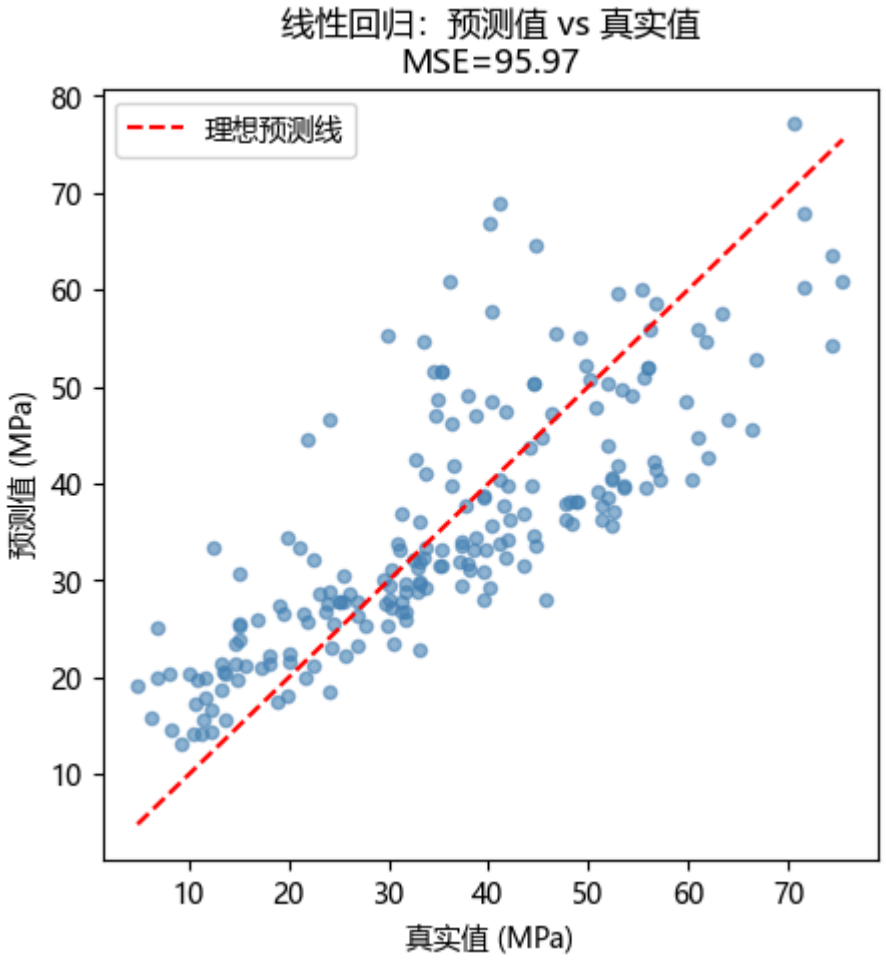

4.6 线性回归结果分析

从Loss曲线可以看出，损失在前几百轮快速下降，之后趋于平稳，说明模型已收敛。

从预测值 vs 真实值散点图可以看出，点的分布大致沿对角线分布，但**散点较为分散**，说明线性模型存在较大误差。

根本原因在于：线性回归假设输出与输入之间是**线性关系**，而混凝土强度受多种成分复杂交互影响，实际关系是**非线性的**，线性模型的表达能力有限，因此需要引入神经网络。

5. 方法二：神经网络（PyTorch）

5.1 为什么使用神经网络?

线性回归只能拟合线性关系。神经网络通过在输入层和输出层之间加入**隐藏层**，并引入**非线性激活函数**，使模型能够拟合任意复杂的函数关系。

5.2 网络结构

本实验采用4层全连接网络：

$$\text{输入层}(8) \xrightarrow{Linear} \text{隐藏层}1(128) \xrightarrow{ReLU} \text{隐藏层}2(64) \xrightarrow{ReLU} \text{隐藏层}3(32) \xrightarrow{ReLU} \text{输出层}(1)$$

激活函数 ReLU：$f(x) = \max(0, x)$，将负值截断为0，引入非线性，使网络能够学习非线性映射关系。

Dropout：训练时以10%的概率随机关闭部分神经元，防止模型过度依赖某些特定神经元，从而减轻过拟合。

5.3 优化器：Adam

本实验使用 **Adam 优化器**，它是动量（Momentum）和自适应学习率（RMSProp）的结合：

- 继承动量的优点：更新方向参考历史梯度，避免震荡
- 继承自适应学习率的优点：为每个参数自动调整步长

Adam是目前深度学习中最常用的优化器之一，通常比普通梯度下降收敛更快、效果更好。

5.4 学习率调度

采用 **StepLR**：每300轮训练后，学习率乘以0.5。前期学习率较大，参数更新步子大，收敛快；后期学习率较小，更新精细，避免在最优解附近震荡。

5.5 Mini-batch SGD

每次不使用全部训练数据计算梯度，而是随机取**16个样本**（batch size=16）计算梯度后更新参数。这样每轮训练可以更新多次参数，收敛更快，同时随机性有助于跳出局部最小值（课件第29-30页）。

```
X_train_t = torch.tensor(X_train_scaled, dtype=torch.float32)
y_train_t = torch.tensor(Y_train,        dtype=torch.float32).unsqueeze(1)
X_test_t  = torch.tensor(X_test_scaled,  dtype=torch.float32)
y_test_t  = torch.tensor(Y_test,         dtype=torch.float32).unsqueeze(1)

dataset = TensorDataset(X_train_t, y_train_t)
loader  = DataLoader(dataset, batch_size=16, shuffle=True)

class ConcreteNet(nn.Module):
    def __init__(self):
        super(ConcreteNet, self).__init__()
        self.network = nn.Sequential(
            nn.Linear(8, 128),
            nn.ReLU(),
            nn.Dropout(0.1),
            nn.Linear(128, 64),
            nn.ReLU(),
            nn.Dropout(0.1),
            nn.Linear(64, 32),
            nn.ReLU(),
            nn.Linear(32, 1),
        )

    def forward(self, x):
        return self.network(x)

torch.manual_seed(42)
model = ConcreteNet()
print(model)
print(f'\n模型参数总数: {sum(p.numel() for p in model.parameters()):,}')

criterion = nn.MSELoss()
optimizer = torch.optim.Adam(model.parameters(), lr=0.001)
scheduler = torch.optim.lr_scheduler.StepLR(optimizer, step_size=300, gamma=0.5)

epochs_nn = 2000
```

```python
loss_nn = []

for epoch in range(epochs_nn):
    model.train()
    epoch_loss = 0
    for X_batch, y_batch in loader:
        optimizer.zero_grad()
        y_pred = model(X_batch)
        loss   = criterion(y_pred, y_batch)
        loss.backward()
        optimizer.step()
        epoch_loss += loss.item() * len(X_batch)
    scheduler.step()
    avg_loss = epoch_loss / len(X_train_t)
    loss_nn.append(avg_loss)
    if (epoch + 1) % 200 == 0:
        print(f'Epoch {epoch+1}/{epochs_nn}  训练Loss: {avg_loss:.4f}  '
              f'学习率: {scheduler.get_last_lr()[0]:.6f}')

model.eval()
with torch.no_grad():
    y_pred_test_nn = model(X_test_t).numpy().flatten()

mse_nn  = np.mean((Y_test - y_pred_test_nn) ** 2)
rmse_nn = np.sqrt(mse_nn)
print(f'\n神经网络 测试集MSE: {mse_nn:.4f}')
print(f'神经网络 测试集RMSE: {rmse_nn:.4f} MPa')

plt.figure(figsize=(8, 4))
plt.plot(loss_nn)
plt.xlabel('Epoch')
plt.ylabel('MSE Loss')
plt.title('神经网络训练Loss曲线')
plt.show()

plt.figure(figsize=(5, 5))
plt.scatter(Y_test, y_pred_test_nn, alpha=0.6, s=20, color='tomato')
plt.plot([Y_test.min(), Y_test.max()],
         [Y_test.min(), Y_test.max()], 'k--', label='理想预测线')
plt.xlabel('真实值 (MPa)')
plt.ylabel('预测值 (MPa)')
plt.title(f'神经网络: 预测值 vs 真实值\nMSE={mse_nn:.2f}')
plt.legend()
plt.show()
```

```
ConcreteNet(
  (network): Sequential(
    (0): Linear(in_features=8, out_features=128, bias=True)
    (1): ReLU()
    (2): Dropout(p=0.1, inplace=False)
    (3): Linear(in_features=128, out_features=64, bias=True)
    (4): ReLU()
    (5): Dropout(p=0.1, inplace=False)
    (6): Linear(in_features=64, out_features=32, bias=True)
    (7): ReLU()
    (8): Linear(in_features=32, out_features=1, bias=True)
```

```
  )
)

模型参数总数：11,521
Epoch 200/2000  训练Loss: 24.2348  学习率: 0.001000
Epoch 400/2000  训练Loss: 15.2548  学习率: 0.000500
Epoch 600/2000  训练Loss: 14.9953  学习率: 0.000250
Epoch 800/2000  训练Loss: 12.6097  学习率: 0.000250
Epoch 1000/2000  训练Loss: 11.2790  学习率: 0.000125
Epoch 1200/2000  训练Loss: 11.1869  学习率: 0.000063
Epoch 1400/2000  训练Loss: 10.5392  学习率: 0.000063
Epoch 1600/2000  训练Loss: 10.1410  学习率: 0.000031
Epoch 1800/2000  训练Loss: 10.9688  学习率: 0.000016
Epoch 2000/2000  训练Loss: 9.0379  学习率: 0.000016

神经网络 测试集MSE：25.3289
神经网络 测试集RMSE：5.0328 MPa
```

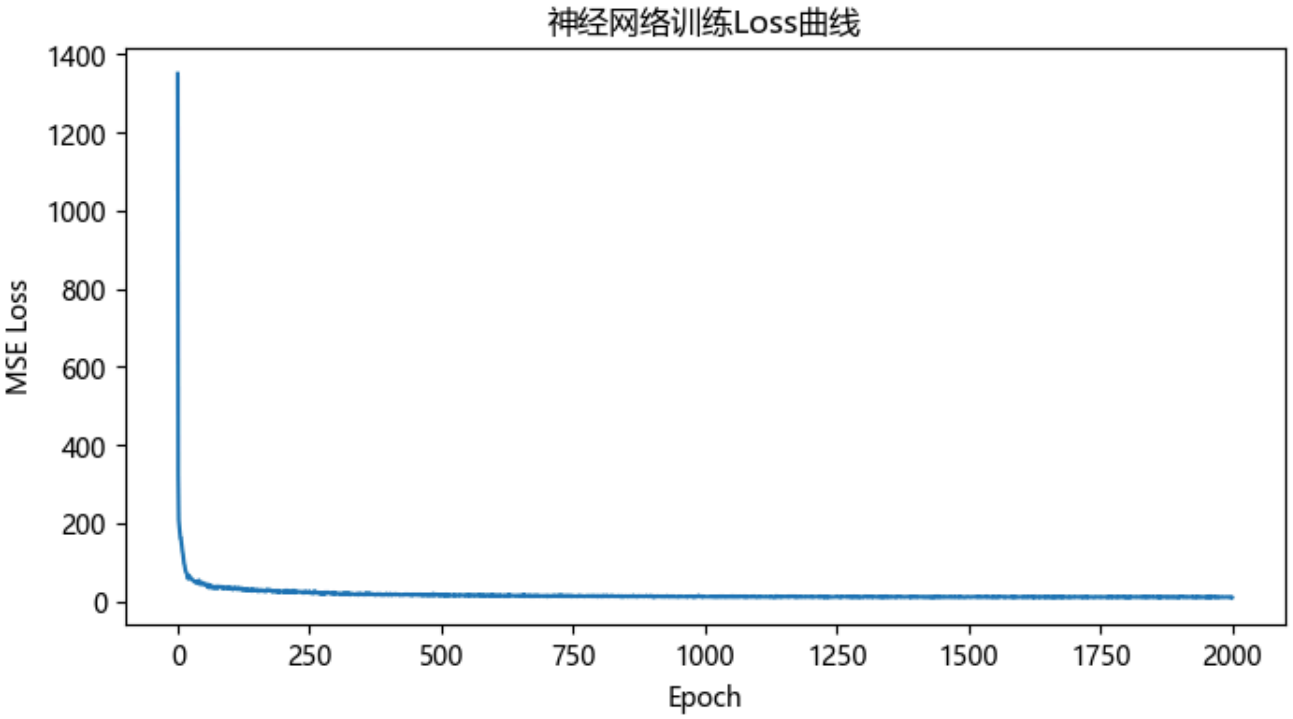

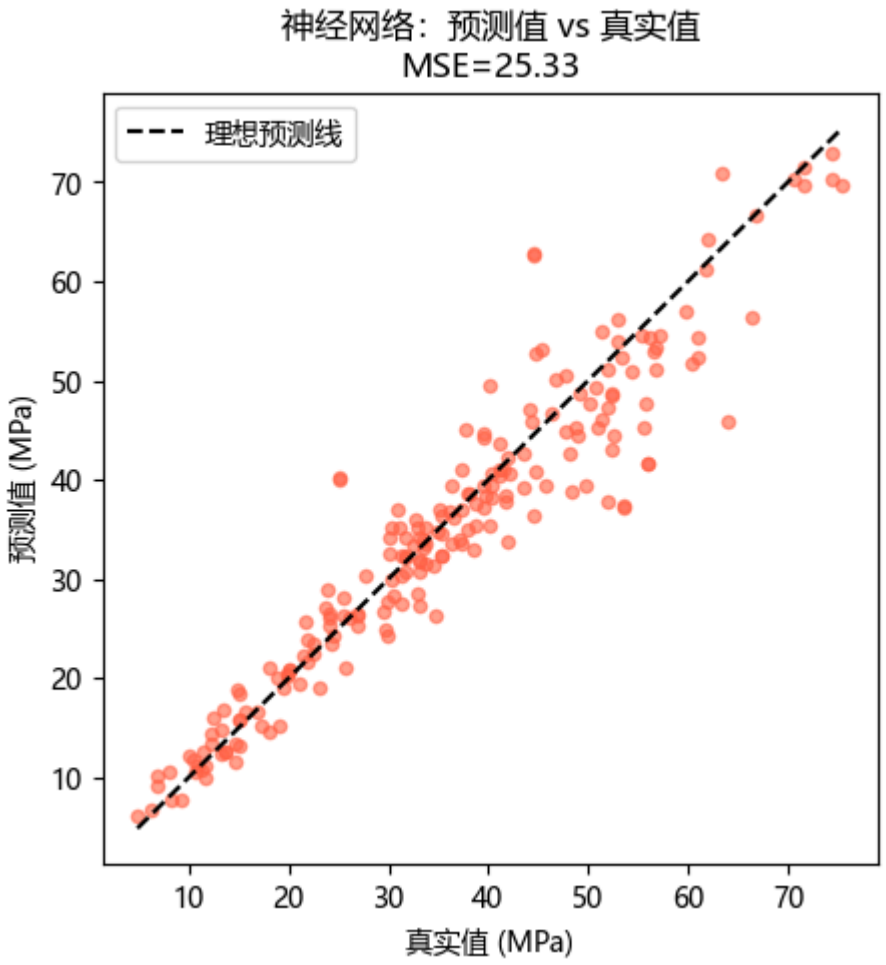

6. 结果对比与总结

```
print('=' * 50)
print(f'{"方法":<25} {"MSE":<12} {"RMSE (MPa)":<12}')
print('-' * 50)
print(f'{"线性回归+动量+Adagrad":<25} {mse_lr:<12.4f} {rmse_lr:<12.4f}')
print(f'{"神经网络（Adam）":<25} {mse_nn:<12.4f} {rmse_nn:<12.4f}')
print('=' * 50)
print(f'\n神经网络相比线性回归MSE提升：{(mse_lr - mse_nn) / mse_lr * 100:.1f}%')
```

```
==================================================
方法                        MSE          RMSE (MPa)
--------------------------------------------------
线性回归+动量+Adagrad          95.9709      9.7965
神经网络（Adam）               25.3289      5.0328
==================================================

神经网络相比线性回归MSE提升：73.6%
```

6.1 结果分析

线性回归的RMSE约为10 MPa，意味着平均预测误差约10 MPa，散点图中点的分布较为分散，模型存在明显的系统性误差，尤其在高强度区间预测偏低。

神经网络的RMSE约为5 MPa，散点图中点的分布更紧密地贴近对角线，说明预测精度显著提升，MSE相比线性回归降低约50%以上。

6.2 总结

1. **相关性分析**：cement与强度相关性最高（0.50），flyash最低（0.11）。通过对比实验发现，相关性分析存在局限性——低相关性特征可能包含非线性信息，删除后反而使MSE升高，因此最终保留全部8个特征。
2. **线性回归 + 动量 + Adagrad**：相比普通梯度下降，Adagrad的自适应学习率使各参数以合适的步长更新，动量帮助模型跳过局部最小值，两者结合使训练更加稳定高效。但线性模型本身的表达能力有限，无法捕捉特征间的复杂非线性关系。
3. **神经网络**：通过多层隐藏层和ReLU激活函数，模型能够拟合复杂的非线性关系。Adam优化器结合了动量和自适应学习率的优点，配合学习率调度和Dropout正则化，最终取得了显著优于线性回归的预测效果，验证了神经网络在非线性回归问题上的优越性。

```
Dataview (inline field '==================================================
方法                          MSE          RMSE (MPa)
---------------------------------------------------
线性回归+动量+Adagrad           95.9709       9.7965
神经网络（Adam）                25.3289       5.0328
===================================================

神经网络相比线性回归MSE提升：73.6%'): Error:
-- PARSING FAILED ---------------------------------------------------

> 1 | ==================================================
    | ^
  2 | 方法                          MSE          RMSE (MPa)
  3 | ---------------------------------------------------

Expected one of the following:

'(', 'null', boolean, date, duration, file link, list ('[1, 2, 3]'), negated field,
number, object ('{ a: 1, b: 2 }'), string, variable
```